

Tecnológico de Costa Rica



Administración de
Tecnología de Información

Curso:

TI6900 Inteligencia de negocios

Proyecto #1

Estudiantes:

Jose Pablo Silesky, 2023135259

Diego León Abarca, 2022008025

Luis Alberto Fernandez Bonilla, 2023143848

Dylan Retana Arce, 2018132666

Gabriel Meza Masís, 2022116316

Profesor:

Lic. Michael Sánchez Soto

I Semestre 2026

Tabla de contenido

Introducción	4
Descripción general del caso	4
Objetivos del proyecto	4
Herramientas seleccionadas	5
1. Comprensión del Caso y Definición de Requerimientos	6
1.1. Descripción del Problema de Negocio	6
1.2. Usuarios de Información	7
1.3. Indicadores Clave (KPIs)	7
1.4. Variables de Análisis	8
1.5. Preguntas de Negocio	8
2. Origen y la estructura de la base de datos transaccional	8
2.1. Descripción general	8
2.2. Estructura del modelo	8
2.2.1. Entidades principales	9
2.2.2. Tablas de relación	9
2.2.3. Tablas de referencia (catálogos)	9
2.3. Integridad y consistencia de los datos	10
3. Diseño del modelo dimensional	11
3.1. Diagrama	11
Tablas de hechos	12
Dimensiones	12
Medidas principales	12
Jerarquías	13
3.1.1. Justificación del diseño	13
3.2. Diccionario de datos de la solución dimensional	13
4. Diseño del ETL	14
4.1. Descripción de reglas de transformación.	15
4.1.1. Separación lógica de entidades	15
4.1.2. Construcción de dimensión fecha	15
4.1.3. Consolidación de reservas repetidas	15
4.1.4. Integración de dimensiones con la tabla de hechos	16
4.2. Descripción de reglas de limpieza	16

4.2.1.	Tratamiento de valores nulos textuales.....	16
4.2.2.	Conversión de tipos de datos	16
4.2.3.	Normalización de fechas para cálculos	16
4.2.4.	Eliminación de duplicados en dimensiones	17
4.3.	Descripción de reglas de homologación.....	17
4.3.1.	Estandarización de nombres de columnas	17
4.3.2.	Homologación de estados de reserva	17
4.3.3.	Homologación de estructura temporal	18
4.4.	Descripción de reglas de derivación y carga	18
4.4.1.	Cálculo de cantidad de huéspedes.....	18
4.4.2.	Cálculo de noches de estadía	18
4.4.3.	Cálculo de antelación de reserva	18
4.4.4.	Derivación de ingreso por servicios	18
4.4.5.	Derivación de ingreso por habitación.....	18
4.4.6.	Derivación de ingreso total.....	18
4.4.7.	Derivación de flags analíticos	19
4.5.	Descripción de reglas de carga	19
4.5.1.	Carga de dimensiones	19
4.5.2.	Carga de tabla de hechos.....	20
4.5.3.	Estructura final de salida.....	20
4.6.	Evidencia de la ejecución del ETL.....	20
4.7.	Documentación de reglas ETL	25
5.	Respuesta a las preguntas de negocio mediante la solución analítica	32
6.		32
7.	implementada.	32
8.	Conclusiones.....	36
8.1.	<i>Limitaciones encontradas</i>	36
8.2.	<i>Posibles mejoras futuras</i>	37
8.3.	<i>Conclusiones</i>	37
	Referencias Bibliográficas.....	38

Introducción

Descripción general del caso

El presente proyecto tiene como caso de estudio una cadena hotelera con múltiples propiedades distribuidas en distintas ubicaciones geográficas, cuya operación genera grandes volúmenes de información provenientes de sistemas de reservas, *check-in* y *check-out*, facturación de servicios complementarios y canales de venta digitales y físicos. La dispersión de estos datos impide que los equipos directivos y operativos cuenten con una visión consolidada del negocio, dificultando la toma de decisiones oportunas y basadas en evidencia.

Entre los principales desafíos identificados se encuentran la ausencia de visibilidad sobre la rentabilidad por propiedad y temporada, la dificultad para analizar el comportamiento de las cancelaciones y los *no-shows*, y el desaprovechamiento del potencial de ingresos provenientes de servicios complementarios como restaurante, spa, tours y traslados. A esto se suma la necesidad de comprender qué canales de reserva y perfiles de huésped generan mayor valor para el negocio.

Para abordar esta problemática, el proyecto diseña e implementa una solución integral de Inteligencia de Negocios que centraliza la información operacional de la cadena hotelera mediante una base de datos transaccional en PostgreSQL, un proceso ETL desarrollado en KNIME Analytics Platform, un modelo dimensional tipo estrella, y una capa analítica implementada en Python sobre Google Colab. Esta solución busca transformar los datos operacionales en conocimiento útil para la gestión estratégica y operativa de la organización.

Objetivos del proyecto

Objetivo General: Diseñar e implementar una solución de Inteligencia de Negocios para una cadena hotelera que integre, transforme y exponga su información operacional mediante un modelo dimensional, un proceso ETL documentado y una capa analítica funcional, con el fin de apoyar la toma de decisiones estratégicas y operativas.

Objetivos Específicos:

- Diseñar una base de datos transaccional en PostgreSQL que modele los procesos operacionales de la cadena hotelera, incluyendo reservas, huéspedes, habitaciones, propiedades, facturación y servicios complementarios.
- Construir un modelo dimensional tipo estrella que permita el análisis multidimensional de la operación hotelera, definiendo dimensiones, métricas y hechos alineados con los KPIs del negocio.
- Implementar un proceso ETL en KNIME Analytics Platform que aplique reglas de limpieza, transformación, homologación y derivación para cargar el modelo dimensional a partir de la fuente transaccional.
- Desarrollar una capa analítica en Python que responda las preguntas de negocio definidas, utilizando los archivos dimensionales generados por el ETL como fuente de datos.

-
- e. Calcular y visualizar los KPIs clave del negocio hotelero —incluyendo Tasa de Ocupación, ADR, RevPAR, Tasa de Cancelación y Tasa de No-Show— para apoyar la toma de decisiones en los distintos niveles organizacionales.

Herramientas seleccionadas

Para el desarrollo de la solución de Inteligencia de Negocios se seleccionaron las siguientes herramientas, tomando en cuenta los requisitos del proyecto y las capacidades de cada plataforma:

- **PostgreSQL:** Sistema gestor de bases de datos relacional de código abierto utilizado para modelar y alojar la base de datos transaccional. Su robustez, soporte para restricciones de integridad referencial y compatibilidad con estándares SQL lo hacen idóneo para representar la operación hotelera con alta fidelidad.
- **KNIME Analytics Platform 5.11.0:** Herramienta visual de código abierto para el diseño y ejecución de flujos ETL. Fue seleccionada por su interfaz basada en nodos que facilita la documentación del proceso, su capacidad para manejar transformaciones complejas (limpieza, agregación, derivación, join dimensional) y por cumplir el requisito del proyecto de utilizar una herramienta ETL distinta de Power BI o Tableau.
- **Python / Jupyter Notebook (Google Colab):** Lenguaje de programación y entorno de ejecución utilizados para implementar la capa analítica de la solución. Mediante bibliotecas como pandas, matplotlib y seaborn se procesan los archivos CSV generados por el ETL y se calculan los KPIs e indicadores de negocio que responden las preguntas definidas. Google Colab fue elegido como entorno de ejecución por su accesibilidad y compatibilidad con el trabajo colaborativo del equipo.
- **Formato CSV (valores separados por comas):** Utilizado como formato de intercambio entre las capas ETL y analítica. Los archivos CSV exportados por KNIME (dimensiones y tabla de hechos) son consumidos directamente por los scripts de Python, garantizando portabilidad y facilidad de integración entre herramientas.

1. Comprensión del Caso y Definición de Requerimientos

1.1.Descripción del Problema de Negocio

Una cadena hotelera con múltiples propiedades distribuidas en distintas ubicaciones geográficas enfrenta el desafío de gestionar grandes volúmenes de información operacional provenientes de diversas fuentes: sistemas de reservas, registros de check-in y check-out, facturación de servicios complementarios, canales de venta digitales y físicos, entre otros. Esta dispersión de datos dificulta la toma de decisiones oportunas y fundamentadas, ya que los equipos directivos y operativos no cuentan con una visión consolidada e integrada del negocio.

La organización necesita comprender, de manera sistemática y confiable, cuáles son las propiedades más rentables, en qué temporadas se concentra la mayor demanda, qué canales de reserva generan mejores resultados en términos de ocupación e ingreso, y qué perfiles de huésped representan mayor valor para el negocio. Sin esta visibilidad, decisiones críticas como la fijación de tarifas, la asignación de recursos por sede, el diseño de campañas de marketing o la gestión de inventario de habitaciones se toman de forma reactiva o basándose en percepciones subjetivas en lugar de evidencia concreta.

A esto se suma la problemática de las cancelaciones y los “*no shows*”, fenómenos que impactan directamente la rentabilidad operativa y que requieren ser analizados en profundidad para identificar patrones según segmento de cliente, canal de reserva y temporada. De igual forma, el comportamiento del huésped respecto al consumo de servicios complementarios como restaurante, spa, tours o traslados representa una fuente de ingresos adicional cuyo potencial no siempre se aprovecha por falta de análisis.

En este contexto, el propósito del presente proyecto es diseñar e implementar una solución integral de Inteligencia de Negocios que permita a la cadena hotelera centralizar su información operacional, transformarla en conocimiento útil y ponerla a disposición de los distintos usuarios de información a través de un modelo dimensional robusto, un proceso ETL documentado y una capa analítica que responda las preguntas clave del negocio. La solución busca apoyar tanto la gestión estratégica, orientada a la rentabilidad y el crecimiento, como de la gestión, enfocada en la eficiencia diaria de cada propiedad.

1.2. Usuarios de Información

Usuario	Rol	Necesidad principal
Gerencia General	Estratégico	Rentabilidad global por propiedad y periodo
Gerencia de Operaciones	Táctico	Ocupación, cancelaciones y desempeño operativo
Área de Revenue Management	Táctico/Operativo	Tarifas, ADR, RevPAR y canales de reserva
Área de Marketing	Táctico	Segmentación de huéspedes y canales efectivos
Gerencia de Experiencia al Cliente	Operativo	Servicios consumidos y perfil del huésped

1.3. Indicadores Clave (KPIs)

KPI	Definición	Fórmula
Tasa de Ocupación	% de habitaciones ocupadas sobre el total disponible	$\text{Habitaciones ocupadas} / \text{Habitaciones disponibles} \times 100$
ADR (Average Daily Rate)	Tarifa promedio cobrada por habitación ocupada	$\text{Ingresos por habitaciones} / \text{Habitaciones vendidas}$
RevPAR	Ingreso por habitación disponible	$\text{ADR} \times \text{Tasa de Ocupación}$
Ingreso total por reserva	Valor monetario total generado por estadía	$\text{Suma de cargos de habitación} + \text{servicios complementarios}$
Tasa de cancelación	% de reservas que fueron canceladas	$\text{Reservas canceladas} / \text{Total reservas} \times 100$
Tasa de no-show	% de reservas donde el huésped no se presentó	$\text{No-shows} / \text{Total reservas confirmadas} \times 100$
Estadía promedio (LOS)	Promedio de noches por reserva	$\text{Total noches} / \text{Total reservas}$
Gasto promedio en servicios complementarios	Consumo promedio en servicios adicionales por huésped	$\text{Ingresos complementarios} / \text{Total huéspedes}$

1.4. Variables de Análisis

- **Tiempo:** fecha de reserva, fecha de check in, fecha de checkout, temporada (alta, media, baja), mes, trimestre, año.
- **Propiedad / Sede:** nombre del hotel, ubicación geográfica, categoría (estrellas), tipo de propiedad (resort, urbano, boutique).
- **Habitación:** tipo (sencilla, doble, suite, etc.), capacidad, tarifa rack, piso o zona.
- **Canal de reserva:** OTA (Booking, Expedia), directo web, agencia de viajes, call center, walkin.
- **Huésped:** nacionalidad, segmento (corporativo, turista, familiar, grupos), motivo de viaje, rango etario, género, recurrencia.
- **Reserva:** estado (confirmada, cancelada, noshow, completada), antelación de reserva, descuento aplicado, forma de pago.
- **Servicios complementarios:** restaurante, spa, tours, traslados, estacionamiento.

1.5. Preguntas de Negocio

Preguntas obligatorias del proyecto:

1. ¿Qué tipos de habitaciones, temporadas y canales de reserva generan mayores ingresos y ocupación?
2. ¿Cómo se comportan las cancelaciones, no shows y estadías promedio según segmento de cliente?
3. ¿Qué sedes o propiedades muestran mejor desempeño en ocupación, ADR e ingreso por habitación disponible (RevPAR)?
4. ¿Qué nacionalidades, motivos de viaje o perfiles de cliente consumen más servicios complementarios?

Pregunta adicional propuesta por el grupo:

5. ¿Con cuánta anticipación se realizan las reservas según canal y segmento, y cómo se relaciona esa antelación con la tasa de cancelación y el ADR obtenido?

2. Origen y la estructura de la base de datos transaccional

2.1. Descripción general

Se diseñó una base de datos relacional en PostgreSQL que simula la operación de una cadena hotelera, con el objetivo de representar los procesos principales asociados a la gestión de reservas, huéspedes, habitaciones, facturación y consumo de servicios. El modelo transaccional constituye la fuente de datos de origen para la solución de inteligencia de negocios, permitiendo capturar información detallada y estructurada que posteriormente será transformada hacia un modelo dimensional.

2.2. Estructura del modelo

El diseño se basa en un enfoque normalizado, separando las entidades principales y sus relaciones para garantizar integridad de los datos, evitar redundancias y facilitar la escalabilidad del sistema.

2.2.1. Entidades principales

- reserva: almacena la información principal de las reservas realizadas, incluyendo fechas, cantidad de huéspedes y monto total.
- huesped: contiene los datos de los clientes, como nombre, contacto, segmento y motivo de viaje.
- habitacion: representa las habitaciones disponibles en cada propiedad.
- propiedad: almacena la información de los hoteles o sedes de la cadena.
- factura: registra la facturación asociada a cada reserva.
- pago: contiene los pagos realizados sobre las facturas.
- consumo_servicio: registra el uso de servicios complementarios por parte de los huéspedes.

2.2.2. Tablas de relación

Se implementaron tablas intermedias para modelar relaciones de tipo muchos-a-muchos:

- reserva_huesped: permite asociar múltiples huéspedes a una misma reserva.
- reserva_habitacion: relaciona las reservas con las habitaciones utilizadas.

2.3. Tablas de referencia (catálogos)

Se incluyen tablas maestras que contienen valores controlados y estandarizados, utilizadas como llaves foráneas:

- país
- ciudad
- tipo_propiedad
- tipo_habitacion
- canal_reserva
- estado_reserva
- metodo_pago
- segmento_cliente
- motivo_viaje
- genero
- rango_etario
- servicio_complementario
- temporada

Estas tablas permiten mantener consistencia en los datos y facilitan el análisis posterior.

- uso de llaves primarias (PK) en todas las tablas
- uso de llaves foráneas (FK) para mantener relaciones entre entidades
- restricciones de unicidad y valores obligatorios
- uso de tipos de datos adecuados para cada atributo

2.5. Justificación del diseño

- comportamiento de reservas
- características de los clientes
- uso de habitaciones
- ingresos por servicios y pagos


Además, su estructura facilita la trazabilidad de los datos hacia el modelo dimensional.



3. Diseño del modelo dimensional

El modelo dimensional se construyó con un esquema estrella centrado en fact_reserva, con el fin de analizar reservas, ingresos y ocupación de forma más sencilla. Las dimensiones asociadas permiten estudiar la información por fecha, propiedad, huésped, habitación, canal, estado de reserva y método de pago. La estructura final se definió de acuerdo con el ETL implementado, donde cada fila representa una reserva única consolidada.

3.1. Diagrama



Para una mejor visualización del diagrama del modelo dimensional, dirigirse al siguiente link: https://lucid.app/lucidchart/2f87613e-5e53-4b63-ae08-3746c09e174f/edit?viewport_loc=-296%2C-2524%2C3630%2C1843%2C0_0&invitationId=inv_ac7437c8-16e4-43be-9a97-1dc9764ba452

Granularidad

La granularidad de fact_reserva es una fila por reserva única consolidada. Esta decisión responde al proceso ETL, en el cual la información original fue agrupada y deduplicada a nivel de reserva, evitando repeticiones derivadas de servicios u otros registros asociados

Tablas de hechos

La tabla de hechos del modelo es fact_reserva. En ella se concentran las métricas más importantes de cada reserva, como la cantidad de huéspedes, la cantidad de noches de estadía, la antelación con que se hizo la reserva, el ingreso total, el ingreso por habitación, el ingreso por servicios y el monto pagado. También incluye indicadores que permiten identificar si una reserva fue cancelada, si terminó en no-show, si fue completada o si llegó a considerarse ocupada.

Dimensiones

El modelo incluye las siguientes dimensiones:

- dim_fecha, que permite analizar la información en el tiempo. En este caso, la fecha principal usada en el ETL fue la de check-in programado. Incluye atributos como fecha, año, mes, trimestre, día, día de la semana y temporada.
- dim_propiedad, que describe la sede o propiedad hotelera mediante el nombre, tipo de propiedad, ciudad y país.
- dim_huesped, que representa al huésped principal de la reserva e incluye datos como correo, nombres, apellidos, teléfono, segmento, motivo y país.
- dim_habitacion, que contiene el tipo y el número de habitación reservado.
- dim_canal, que identifica el canal por medio del cual se realizó la reserva.
- dim_estado_reserva, que clasifica el estado de la reserva, por ejemplo confirmada, cancelada, no-show o completada.
- dim_metodo_pago, que representa el método de pago o garantía asociado a la reserva.

Medidas principales

Entre las medidas más importantes de fact_reserva se encuentran: adultos, niños, infantes, cantidad_huespedes, noches_estadia, antelacion_reserva_dias, ingreso_total, ingreso_habitacion, ingreso_servicios y monto_pago. Además, se incluyen las banderas flag_cancelada, flag_noshow, flag_completada y flag_ocupada, que ayudan a calcular indicadores relacionados con cancelaciones, no-shows y ocupación.

Jerarquías

Dentro del modelo se definieron las siguientes jerarquías:

- Tiempo: Año → Trimestre → Mes → Día
- Ubicación: País → Ciudad → Propiedad
- Habitación: Tipo de habitación → Número de habitación

3.2. Justificación del diseño

Se decidió trabajar con un esquema estrella de una sola tabla de hechos porque esa fue la estructura que mejor se ajustó al ETL implementado. De esta forma, se mantiene coherencia entre la base de datos de origen, el proceso ETL y el modelo dimensional final. Además, los servicios complementarios sí quedaron contemplados, pero integrados dentro de la medida ingreso_servicios, en lugar de crear otra tabla de hechos separada.

3.3. Diccionario de datos de la solución dimensional

A continuación, se presenta un diccionario de datos resumido de la solución dimensional implementada. Este incluye las tablas principales del modelo estrella, sus campos más relevantes, el tipo de dato y una breve descripción funcional.

Tabla	Campo	Tipo de dato	Descripción
dim_fecha	mes	int	Mes de la fecha
dim_fecha	trimestre	int	Trimestre de la fecha
dim_fecha	día	int	Día del mes
dim_fecha	día_semana	string	Nombre o descripción del día de la semana
dim_fecha	temporada	string	Temporada asociada a la fecha
dim_propiedad	sk_propiedad	int	Clave primaria de la dimensión propiedad
dim_propiedad	nombre_propiedad	string	Nombre del hotel o propiedad
dim_propiedad	tipo_propiedad	string	Tipo de propiedad, por ejemplo hotel, resort o boutique
dim_propiedad	nombre_ciudad	string	Ciudad donde se ubica la propiedad
dim_propiedad	nombre_pais	string	País donde se ubica la propiedad
dim_huesped	sk_huesped	int	Clave primaria de la dimensión huésped
dim_huesped	email	string	Correo del huésped usado como clave natural de integración
dim_huesped	nombres	string	Nombres del huésped
dim_huesped	apellidos	string	Apellidos del huésped
dim_huesped	telefono	string	Número telefónico del huésped
dim_huesped	nombre_segmento	string	Segmento al que pertenece el huésped
dim_huesped	nombre_motivo	string	Motivo de viaje asociado al huésped
dim_huesped	nombre_pais	string	País o nacionalidad del huésped

Tabla	Campo	Tipo de dato	Descripción
dim_habitacion	sk_habitacion	int	Clave primaria de la dimensión habitación
dim_habitacion	tipo_habitacion	string	Tipo de habitación reservada
dim_habitacion	numero_habitacion	string	Número o código de la habitación
dim_canal	sk_canal	int	Clave primaria de la dimensión canal
dim_canal	nombre_canal	string	Nombre del canal de reserva
dim_estado_reserva	sk_estado	int	Clave primaria de la dimensión estado
dim_estado_reserva	nombre_estado	string	Estado operativo de la reserva
dim_metodo_pago	sk_metodo_pago	int	Clave primaria de la dimensión método de pago
dim_metodo_pago	nombre_metodo	string	Nombre del método de pago o garantía

4. Diseño del ETL

El proceso ETL fue diseñado para transformar un archivo transaccional de reservas hoteleras en un conjunto de tablas dimensionales y una tabla de hechos aptas para análisis de inteligencia de negocios. La solución se implementó en **KNIME Analytics Platform 5.11.0**, herramienta seleccionada para cumplir con el requisito del proyecto de utilizar un proceso ETL distinto de Power BI o Tableau.

El archivo de origen contenía información de reservas, huéspedes, propiedades, habitaciones, canales, estados, métodos de pago y servicios complementarios. Debido a la naturaleza de la fuente, una misma reserva podía aparecer en múltiples filas cuando existían consumos de servicios asociados, por lo que fue necesario aplicar procesos de limpieza, normalización, consolidación y derivación para obtener una granularidad final de una fila por reserva.

Resultado final del ETL

El proceso genera como salida:

Dimensiones:

- dim_fecha.csv
- dim_propiedad.csv
- dim_huesped.csv
- dim_habitacion.csv
- dim_canal.csv
- dim_estado_reserva.csv
- dim_metodo_pago.csv

Tabla de hechos:

- fact_reserva.csv

Granularidad final:

Una fila por reserva única consolidada

4.1.Descripción de reglas de transformación.

Esta sección explica qué se transformó estructuralmente.

4.1.1. Separación lógica de entidades

A partir del archivo transaccional de origen, se separaron subconjuntos de datos para construir dimensiones independientes correspondientes a:

- Fecha
- Propiedad
- Huésped
- Habitación
- Canal de reserva
- Estado de reserva
- Método de pago

Cada dimensión se construyó mediante selección de columnas relevantes, eliminación de duplicados y generación de llaves subrogadas.

4.1.2. Construcción de dimensión fecha

Se generó una dimensión de tiempo a partir de las fechas presentes en el *dataset*, extrayendo componentes analíticos como:

- año
- trimestre (*quarter*)
- mes
- día de la semana
- día

Esta dimensión fue posteriormente utilizada para asociar la tabla de hechos mediante la fecha de check-in programado, al considerarse la referencia temporal más útil para análisis de ocupación e ingresos.

4.1.3. Consolidación de reservas repetidas

Dado que el *dataset* podía repetir una reserva en varias filas debido a servicios complementarios asociados, se aplicó un proceso de agrupación (GroupBy) utilizando como claves:

- id_reserva
- codigo_reserva

Sobre esa agrupación se definieron reglas de agregación diferenciadas:

Para atributos descriptivos:

Se utilizó agregación First, ya que el valor debía ser único y consistente por reserva.

Para montos:

- monto_total_reserva → First
- total_factura → First
- monto_pago → Sum
- total_servicio → Sum

Esto permitió evitar duplicaciones de ingresos provocadas por la repetición de filas a nivel de servicio.

4.1.4. Integración de dimensiones con la tabla de hechos

Una vez construidas las dimensiones, se integraron sus llaves subrogadas a la tabla de hechos mediante nodos Joiner en KNIME, sustituyendo claves naturales por claves analíticas:

- fecha_checkin_programado ↔ dim_fecha.fecha
- nombre_propiedad + tipo_propiedad + nombre_ciudad + nombre_pais ↔ dim_propiedad
- email ↔ dim_huesped
- tipo_habitacion + numero_habitacion ↔ dim_habitacion
- nombre_canal ↔ dim_canal
- nombre_estado ↔ dim_estado_reserva
- nombre_metodo ↔ dim_metodo_pago

4.2. Descripción de reglas de limpieza

Esta sección explica qué datos “sucios” o inconsistentes se corrigieron.

4.2.1. Tratamiento de valores nulos textuales

En el dataset original se detectaron valores textuales como:

- "NULL"
- "NULE" (error de digitación presente en algunos registros)

Estos valores aparecían en columnas monetarias como total_factura y provocaban errores de conversión numérica en KNIME.

Regla aplicada: Se reemplazaron estos valores por nulos reales o por cero, según el contexto de negocio, antes de convertir las columnas a tipo numérico.

Objetivo: Evitar errores de ejecución en nodos de agregación, conversión y fórmulas matemáticas.

4.2.2. Conversión de tipos de datos

Se realizaron conversiones explícitas para asegurar consistencia entre tipos:

- columnas monetarias → tipo numérico
- fechas → tipo Date
- fecha y hora → tipo Date&Time cuando correspondía

Esto fue especialmente importante en el cálculo de diferencias de fechas, ya que algunas columnas estaban en formato Date&Time y otras solo en Date.

4.2.3. Normalización de fechas para cálculos

Se detectó una inconsistencia entre:

- fecha_reserva (tipo Date&Time)
- fecha_checkin_programado y fecha_checkout_programado (tipo Date)

Para permitir cálculos como antelación de reserva y noches de estadía, se estandarizaron temporalmente los tipos de fecha mediante nodos de conversión, asegurando compatibilidad entre ambos campos.

4.2.4. Eliminación de duplicados en dimensiones

Antes de generar las llaves subrogadas de cada dimensión, se eliminaron duplicados utilizando combinaciones de atributos naturales según cada entidad, con el fin de evitar múltiples claves para el mismo valor de negocio. Ejemplos:

- dim_canal → un registro por nombre_canal
- dim_estado_reserva → un registro por nombre_estado
- dim_habitacion → un registro por combinación de tipo_habitacion + numero_habitacion

4.3. Descripción de reglas de homologación

Esta sección explica cómo se estandarizaron nombres/valores para que el modelo fuera consistente.

4.3.1. Estandarización de nombres de columnas

Se homologaron nombres de columnas para que la salida dimensional y la tabla de hechos tuvieran una nomenclatura consistente y orientada al análisis. Ejemplos:

- uso uniforme del prefijo sk_ para llaves subrogadas
- uso de nombres descriptivos como:
 - sk_fecha
 - sk_propiedad
 - sk_huesped
 - sk_habitacion
 - sk_canal
 - sk_estado
 - sk_metodo_pago

4.3.2. Homologación de estados de reserva

Los estados de reserva se normalizaron para trabajar con un conjunto reducido y analíticamente útil de categorías:

- Confirmada
- Cancelada
- NoShow
- Completada

A partir de estos estados se derivaron indicadores binarios que facilitan el análisis:

- flag_cancelada

- flag_noshow
- flag_completada
- flag_ocupada

4.3.3. Homologación de estructura temporal

Aunque existían múltiples fechas en el *dataset* (fecha de reserva, *check-in*, *check-out*), se homologó el análisis temporal principal utilizando la fecha de check-in programado como referencia para la relación con dim_fecha. Esto permitió mantener una sola clave temporal principal en la tabla de hechos y simplificar el modelo dimensional.

4.4. Descripción de reglas de derivación y carga

Esta sección explica **qué campos nuevos se calcularon**.

4.4.1. Cálculo de cantidad de huéspedes

Se creó la métrica: cantidad_huespedes

Regla: adultos + niños + infantiles

4.4.2. Cálculo de noches de estadía

Se creó la métrica: noches_estadia

Regla: fecha_checkout_programado - fecha_checkin_programado

Esta medida representa la duración planificada de la reserva.

4.4.3. Cálculo de antelación de reserva

Se creó la métrica: antelacion_reserva_dias

Regla: fecha_checkin_programado - fecha_reserva (considerando conversión previa de tipos de fecha)

Esta variable se utilizó como indicador para analizar comportamiento de compra anticipada y su relación con cancelaciones e ingresos.

4.4.4. Derivación de ingreso por servicios

Se consolidó la métrica: ingreso_servicios

Regla: Corresponde a la suma de total_servicio por reserva durante el proceso de agrupación.

4.4.5. Derivación de ingreso por habitación

Se creó la métrica: ingreso_habitacion

Regla aplicada: monto_total_reserva - total_servicio

Esta regla se utilizó porque el dataset consolidado permitía interpretar monto_total_reserva como el total de la reserva y total_servicio como el componente adicional de servicios complementarios.

4.4.6. Derivación de ingreso total

Se homologó la métrica: ingreso_total

Regla: ingreso_total = monto_total_reserva

De esta manera, el ingreso total de la reserva se conserva como valor principal consolidado.

4.4.7. Derivación de flags analíticos

Se crearon indicadores binarios para facilitar cálculos de KPIs:

- **flag_cancelada**

1 si nombre_estado = "Cancelada" y 0 en otro caso

- **flag_noshow**

1 si nombre_estado = "NoShow" y 0 en otro caso

- **flag_completada**

1 si nombre_estado = "Completada" y 0 en otro caso

- **flag_ocupada**

1 si nombre_estado = "Completada" y 0 en otro caso

Se definió flag_ocupada con base en reservas completadas, ya que esta aproximación representa mejor la ocupación operativa real y es más defendible para el análisis del caso.

4.5.Descripción de reglas de carga

Esta parte explica cómo quedó el output.

4.5.1. Carga de dimensiones

Cada dimensión fue exportada a formato CSV mediante nodos CSV Writer, conservando:

- encabezados de columnas
- sin necesidad de RowIDs como dato analítico
- una fila por valor único de la dimensión

Archivos generados:

- dim_fecha.csv
- dim_propiedad.csv
- dim_huesped.csv
- dim_habitacion.csv
- dim_canal.csv
- dim_estado_reserva.csv
- dim_metodo_pago.csv

4.5.2. Carga de tabla de hechos

La tabla fact_reserva fue construida tras la integración de llaves subrogadas y la selección final de columnas analíticas. Columnas incluidas:

- identificadores de negocio
- llaves foráneas dimensionales
- métricas
- indicadores binarios derivados

Archivo generado:


- fact_reserva.csv

4.5.3. Estructura final de salida

Los archivos fueron exportados a una carpeta de salida local para ser consumidos posteriormente por la capa analítica (Python / Jupyter / Google Colab), en cumplimiento del requerimiento de implementar una solución analítica funcional distinta del ETL y del modelo dimensional.

4.6. Evidencia de la ejecución del ETL

Evidencia 1: Vista general del workflow completo




Evidencia 2: Preview del CSV Reader mostrando columnas y cantidad de filas

File Table (Table)


Rows: 1530 | Columns: 28

#	RowID	id_reserva Number (...)	codigo_re... String	fecha_res... String	fecha_ch... String	fecha_ch... String	adultos Number (...)	ninios Number (...)	infantes Number (...)	mc ID
1	Row0	652	RES000652	2025-03-11 10:1	2025-04-03	2025-04-08	1	1	0	490.42
2	Row1	652	RES000652	2025-03-11 10:1	2025-04-03	2025-04-08	1	1	0	490.42
3	Row2	273	RES000273	2026-07-04 10:1	2026-07-08	2026-07-12	2	0	0	768.4
4	Row3	51	RES000051	2025-03-13 10:1	2025-05-04	2025-05-08	1	0	0	528.84
5	Row4	839	RES000839	2026-03-06 10:1	2026-04-05	2026-04-11	3	0	0	743.09
6	Row5	839	RES000839	2026-03-06 10:1	2026-04-05	2026-04-11	3	0	0	743.09
7	Row6	839	RES000839	2026-03-06 10:1	2026-04-05	2026-04-11	3	0	0	743.09
8	Row7	70	RES000070	2025-03-25 10:1	2025-06-04	2025-06-09	1	0	0	600.88
9	Row8	70	RES000070	2025-03-25 10:1	2025-06-04	2025-06-09	1	0	0	600.88
10	Row9	350	RES000350	2025-01-14 10:1	2025-04-05	2025-04-08	1	0	0	411.6
11	Row10	350	RES000350	2025-01-14 10:1	2025-04-05	2025-04-08	1	0	0	411.6
12	Row11	350	RES000350	2025-01-14 10:1	2025-04-05	2025-04-08	1	0	0	411.6
13	Row12	539	RES000539	2026-01-25 10:1	2026-04-25	2026-05-01	3	0	0	968.41
14	Row13	539	RES000539	2026-01-25 10:1	2026-04-25	2026-05-01	3	0	0	968.41
15	Row14	539	RES000539	2026-01-25 10:1	2026-04-25	2026-05-01	3	0	0	968.41
16	Row15	758	RES000758	2025-09-09 10:1	2025-10-18	2025-10-21	3	0	0	748.06
17	Row16	758	RES000758	2025-09-09 10:1	2025-10-18	2025-10-21	3	0	0	748.06
18	Row17	758	RES000758	2025-09-09 10:1	2025-10-18	2025-10-21	3	0	0	748.06
19	Row18	874	RES000874	2026-04-03 10:1	2026-06-07	2026-06-12	2	0	0	621.84
20	Row19	874	RES000874	2026-04-03 10:1	2026-06-07	2026-06-12	2	0	0	621.84
21	Row20	278	RES000278	2026-07-16 10:1	2026-07-25	2026-07-28	3	0	0	741.73
22	Row21	278	RES000278	2026-07-16 10:1	2026-07-25	2026-07-28	3	0	0	741.73
23	Row22	278	RES000278	2026-07-16 10:1	2026-07-25	2026-07-28	3	0	0	741.73
24	Row23	176	RES000176	2025-10-21 10:1	2026-01-16	2026-01-19	3	1	0	483.64
25	Row24	176	RES000176	2025-10-21 10:1	2026-01-16	2026-01-19	3	1	0	483.64


Evidencia 3: Construcción de dim_fecha




Evidencia 4: GroupBy de consolidación de reservas



Evidencia 5: limpieza de nulos / reemplazo de "NULL" / "NULE"



Evidencia 6: Joiners con dimensiones




Evidencia 7: Tabla final fact_reserva

Output data (Table)

Rows: 500 | Columns: 26

#	RowID	sk_fecha_f	sk_fecha	sk_propie	sk_huemp	sk_habita	sk_canal	sk_estado	sk_metod	moneda_p	adultos	ninos	infantes	noches_e	cantidad	flag_canc	flag	
1	Row0	Row0,Row555, 1	RES000001	Row1475	Row2	Row1352	Row1355	Row0	Row1350	Row1350	0	1	0	0	2	1	1	0
2	Row1	Row1,Row551, 2	RES000002	Row1388	Row7	Row1388	Row1354	Row3	Row1350	Row1350	0	1	0	0	3	1	1	0
3	Row2	Row2,Row551, 3	RES000003	Row1451	Row3	Row1407	Row1386	Row35	Row1350	Row1350	0	2	0	0	4	2	1	0
4	Row3	Row3,Row553, 4	RES000004	Row1390	Row0	Row1390	Row1373	Row34	Row1351	Row1350	0	2	1	0	5	3	0	1
5	Row4	Row4,Row197, 5	RES000005	Row402	Row2	Row45	Row167	Row20	Row87	Row2	163.62	2	0	0	6	2	0	0
6	Row5	Row5,Row178, 6	RES000006	Row353	Row7	Row522	Row178	Row4	Row87	Row9	51.35	3	2	0	1	5	0	0
7	Row6	Row6,Row244, 7	RES000007	Row518	Row3	Row89	Row118	Row2	Row0	Row9	865.58	3	0	0	2	3	0	0
8	Row7	Row7,Row226, 8	RES000008	Row470	Row6	Row269	Row277	Row0	Row0	Row3	1,450.92	3	1	0	3	4	0	0
9	Row8	Row8,Row147, 9	RES000009	Row289	Row2	Row435	Row198	Row3	Row0	Row0	320.92	3	0	0	4	3	0	0
10	Row9	Row9,Row47, 10	RES000010	Row96	Row7	Row96	Row96	Row25	Row0	Row4	889.24	1	0	0	5	1	0	0
11	Row10	Row10,Row111, 11	RES000011	Row710	Row3	Row459	Row150	Row34	Row0	Row2	2,171.87	1	0	0	6	1	0	0
12	Row11	Row11,Row26, 12	RES000012	Row56	Row0	Row260	Row0	Row20	Row0	Row9	132.21	1	2	1	1	4	0	0
13	Row12	Row12,Row53, 13	RES000013	Row114	Row2	Row114	Row48	Row4	Row0	Row3	833.26	2	0	0	2	2	0	0
14	Row13	Row13,Row19, 14	RES000014	Row385	Row7	Row518	Row162	Row2	Row0	Row0	1,267.86	2	0	0	3	2	0	0
15	Row14	Row14,Row37, 15	RES000015	Row876	Row3	Row88	Row65	Row0	Row0	Row4	332.22	2	0	0	4	2	0	0
16	Row15	Row15,Row30, 16	RES000016	Row1093	Row0	Row459	Row23	Row3	Row0	Row2	889.84	3	1	0	5	4	0	0
17	Row16	Row16,Row67, 17	RES000017	Row137	Row2	Row274	Row519	Row35	Row0	Row5	2,030.61	3	0	0	6	3	0	0
18	Row17	Row17,Row18, 18	RES000018	Row39	Row7	Row147	Row59	Row34	Row0	Row3	127.13	3	2	0	1	5	0	0
19	Row18	Row18,Row35, 19	RES000019	Row78	Row3	Row78	Row78	Row20	Row0	Row0	847.96	3	0	0	2	3	0	0
20	Row19	Row19,Row31, 20	RES000020	Row737	Row0	Row181	Row351	Row4	Row0	Row4	1,386.36	1	1	0	3	2	0	0
21	Row20	Row20,Row55, 21	RES000021	Row1410	Row2	Row1376	Row1410	Row2	Row1350	Row1350	0	1	0	0	4	1	1	0
22	Row21	Row21,Row540, 22	RES000022	Row1406	Row7	Row1442	Row1364	Row0	Row1350	Row1350	0	1	0	0	5	1	1	0
23	Row22	Row22,Row56, 23	RES000023	Row1422	Row3	Row451	Row1389	Row3	Row1350	Row1350	0	2	0	0	6	2	1	0
24	Row23	Row23,Row511, 24	RES000024	Row1373	Row0	Row1377	Row1353	Row35	Row1351	Row1350	0	2	2	1	1	5	0	1
25	Row24	Row24,Row6, 25	RES000025	Row167	Row2	Row897	Row372	Row34	Row87	Row9	134.24	2	0	0	2	2	0	0
26	Row25	Row25,Row54, 26	RES000026	Row178	Row7	Row353	Row144	Row20	Row87	Row3	126.11	3	0	0	3	3	0	0
27	Row26	Row26,Row76, 27	RES000027	Row149	Row3	Row149	Row149	Row4	Row0	Row3	341.71	3	0	0	4	3	0	0
28	Row27	Row27,Row21, 28	RES000028	Row1249	Row0	Row381	Row42	Row2	Row0	Row0	889.84	3	1	0	5	4	0	0
29	Row28	Row28,Row311, 29	RES000029	Row702	Row2	Row198	Row51	Row0	Row0	Row4	2,030.61	3	0	0	6	3	0	0
30	Row29	Row29,Row12, 30	RES000030	Row231	Row7	Row231	Row9	Row3	Row0	Row2	123.45	1	2	0	1	3	0	0
31	Row30	Row30,Row21, 31	RES000031	Row427	Row3	Row427	Row332	Row35	Row0	Row9	865.58	1	0	0	2	1	0	0
32	Row31	Row31,Row0, 32	RES000032	Row0	Row0	Row56	Row555	Row34	Row0	Row3	1,431.6	1	1	0	3	2	0	0
33	Row32	Row32,Row40, 33	RES000033	Row972	Row2	Row568	Row559	Row20	Row0	Row0	348.04	2	0	0	4	2	0	0
34	Row33	Row33,Row12, 34	RES000034	Row247	Row7	Row247	Row4	Row0	Row4	Row4	882.08	2	0	0	5	2	0	0
35	Row34	Row34,Row48, 35	RES000035	Row48	Row3	Row48	Row48	Row2	Row0	Row2	2,142.82	2	0	0	6	2	0	0
36	Row35	Row35,Row264, 36	RES000036	Row575	Row0	Row575	Row202	Row0	Row0	Row9	123.74	3	2	1	1	6	0	0
37	Row36	Row36,Row149, 37	RES000037	Row1313	Row3	Row1317	Row84	Row3	Row3	Row3	473.43	1	0	0	1	1	0	0

Evidencia 8: CSV Writers finales



OneDrive > ... > TEC > ATI > Semestre > 9 Semestre > Inteligencia de Negocios Vol 3 > Proyecto > Proyecto 1 > ETL_hotel > Output

Nombre	Estado	Fecha de modificación	Tipo	Tamaño
dim_canal.csv	● R	21/4/26 21:59	Archivo de origen Com...	1 KB
dim_estado_reserva.csv	● R	21/4/26 21:59	Archivo de origen Com...	1 KB
dim_fecha.csv	● R	21/4/26 21:57	Archivo de origen Com...	41 KB
dim_habitacion.csv	● R	21/4/26 21:59	Archivo de origen Com...	4 KB
dim_huesped.csv	● R	21/4/26 21:58	Archivo de origen Com...	35 KB
dim_metodo_pago.csv	● R	21/4/26 22:00	Archivo de origen Com...	1 KB
dim_propiedad.csv	● R	21/4/26 21:58	Archivo de origen Com...	1 KB
fact_reserva.csv	● R	21/4/26 21:52	Archivo de origen Com...	199 KB

4.7.Documentación de reglas ETL

El siguiente cuadro documenta los campos destino, origen y reglas aplicadas en el proceso ETL

Campo destino	Campo origen	Regla aplicada	Comentarios
dim_fecha.sk_fecha	Fecha única derivada de fecha_checkin_programado	Generación de llave subrogada secuencial para la dimensión	Llave analítica utilizada para relacionar la tabla de hechos con la dimensión de tiempo
dim_fecha.fecha	fecha_checkin_programado	Selección directa y normalización a tipo fecha	Se definió como fecha analítica principal del modelo
dim_fecha.anio	fecha_checkin_programado	Extracción de componente fecha	Permite agregación anual
dim_fecha.mes	fecha_checkin_programado	Extracción de componente fecha	Permite agregación mensual
dim_fecha.dia	fecha_checkin_programado	Extracción de componente fecha	Permite análisis diario
dim_fecha.trimestre	fecha_checkin_programado	Extracción de quarter / trimestre	El atributo quarter fue homologado conceptualmente como trimestre
dim_fecha.dia_semana	fecha_checkin_programado	Extracción de día de la semana	Útil para análisis de patrones de check-in

Campo destino	Campo origen	Regla aplicada	Comentarios
dim_propiedad.sk_propiedad	nombre_propiedad, tipo_propiedad, nombre_ciudad, nombre_pais	Eliminación de duplicados + generación de llave subrogada	Se construyó una fila única por propiedad
dim_propiedad.nombre_propiedad	nombre_propiedad	Selección directa	Nombre comercial de la sede/hotel
dim_propiedad.tipo_propiedad	tipo_propiedad	Selección directa	Clasificación analítica de la propiedad
dim_propiedad.nombre_ciudad	nombre_ciudad	Selección directa	Nivel geográfico intermedio
dim_propiedad.nombre_pais	nombre_pais	Selección directa	Nivel geográfico superior
dim_huesped.sk_huesped	email	Eliminación de duplicados + generación de llave subrogada	Se utilizó el correo electrónico como clave natural de integración
dim_propiedad.nombre_propiedad	nombre_propiedad	Selección directa	Nombre comercial de la sede/hotel
dim_propiedad.tipo_propiedad	tipo_propiedad	Selección directa	Clasificación analítica de la propiedad

Campo destino	Campo origen	Regla aplicada	Comentarios
dim_propiedad.nombre_ciudad	nombre_ciudad	Selección directa	Nivel geográfico intermedio
dim_propiedad.nombre_pais	nombre_pais	Selección directa	Nivel geográfico superior
dim_huesped.sk_huesped	email	Eliminación de duplicados + generación de llave subrogada	Se utilizó el correo electrónico como clave natural de integración
dim_huesped.email	email	Selección directa	Identificador natural del huésped titular
dim_huesped.nombres	nombres	Selección directa	Atributo descriptivo del huésped
dim_huesped.apellidos	apellidos	Selección directa	Atributo descriptivo del huésped
dim_huesped.telefono	telefono	Selección directa	Dato de contacto del huésped
dim_huesped.nombre_segmento	nombre_segmento	Selección directa	Segmentación comercial del cliente
dim_huesped.nombre_motivo	nombre_motivo	Selección directa	Motivo principal del viaje

Campo destino	Campo origen	Regla aplicada	Comentarios
dim_huesped.nombre_pais	nombre_pais	Selección directa	País o nacionalidad asociada al huésped
dim_habitacion.sk_habitacion	tipo_habitacion, numero_habitacion	Eliminación de duplicados + generación de llave subrogada	Se definió una fila única por habitación
dim_habitacion.tipo_habitacion	tipo_habitacion	Selección directa	Clasificación de la habitación
dim_habitacion.numero_habitacion	numero_habitacion	Selección directa	Identificador operativo de la habitación
dim_canal.sk_canal	nombre_canal	Eliminación de duplicados + generación de llave subrogada	Una fila única por canal de reserva
dim_canal.nombre_canal	nombre_canal	Selección directa	Canal comercial de origen de la reserva
dim_estado_reserva.sk_estado	nombre_estado	Eliminación de duplicados + generación de llave subrogada	Una fila única por estado de reserva
dim_estado_reserva.nombre_estado	nombre_estado	Selección directa	Estado operativo de la reserva
dim_metodo_pago.sk_metodo_pago	nombre_metodo	Eliminación de duplicados + generación de llave subrogada	Una fila única por método de pago

Campo destino	Campo origen	Regla aplicada	Comentarios
dim_metodo_pago.nombre_metodo	nombre_metodo	Selección directa	Método de pago o garantía de la reserva
fact_reserva.id_reserva	id_reserva	Selección directa + uso como clave de agrupación	Identificador técnico de negocio de la reserva
fact_reserva.codigo_reserva	codigo_reserva	Selección directa + uso como clave de agrupación	Código visible / funcional de la reserva
fact_reserva.sk_fecha	fecha_checkin_programado → dim_fecha.fecha	Join con dimensión fecha	Se reemplazó la fecha natural por llave subrogada
fact_reserva.sk_propiedad	nombre_propiedad, tipo_propiedad, nombre_ciudad, nombre_pais → dim_propiedad	Join con dimensión propiedad	Se reemplazaron atributos naturales por llave subrogada
fact_reserva.sk_huesped	email → dim_huesped.email	Join con dimensión huésped	Se utilizó email como criterio de integración
fact_reserva.sk_habitacion	tipo_habitacion, numero_habitacion → dim_habitacion	Join con dimensión habitación	Join compuesto por tipo + número
fact_reserva.sk_canal	nombre_canal → dim_canal.nombre_canal	Join con dimensión canal	Se reemplazó el valor textual por llave subrogada

Campo destino	Campo origen	Regla aplicada	Comentarios
fact_reserva.sk_estado	nombre_estado → dim_estado_reserva.nombre_estado	Join con dimensión estado	Se reemplazó el estado textual por llave subrogada
fact_reserva.sk_metodo_pago	nombre_metodo → dim_metodo_pago.nombre_metodo	Join con dimensión método de pago	Se reemplazó el método textual por llave subrogada
fact_reserva.adultos	adultos	Agregación tipo First en GroupBy	Valor constante por reserva
fact_reserva.ninos	ninos	Agregación tipo First en GroupBy	Valor constante por reserva
fact_reserva.infantes	infantes	Agregación tipo First en GroupBy	Valor constante por reserva
fact_reserva.cantidad_huespedes	adultos, ninos, infantes	Derivación: suma de componentes	Métrica derivada para análisis de ocupación y perfil de reserva
fact_reserva.noches_estadia	fecha_checkout_programado, fecha_checkin_programado	Derivación: diferencia de fechas	Representa la duración planificada de la estadía
fact_reserva.antelacion_reserva_dias	fecha_checkin_programado, fecha_reserva	Derivación: diferencia de fechas con normalización previa de tipos	Mide cuántos días antes se realizó la reserva
fact_reserva.monto_pago	monto_pago	Agregación tipo Sum en GroupBy	Se consolidó el total pagado por reserva

Campo destino	Campo origen	Regla aplicada	Comentarios
fact_reserva.ingreso_servicios	total_servicio	Agregación tipo Sum en GroupBy	Suma de servicios complementarios asociados a la reserva
fact_reserva.ingreso_total	monto_total_reserva	Agregación tipo First en GroupBy y homologación semántica	Se asumió como total consolidado de la reserva
fact_reserva.ingreso_habitacion	monto_total_reserva, total_servicio	Derivación: monto_total_reserva - total_servicio	Aproximación del ingreso atribuible a habitación
fact_reserva.flag_cancelada	nombre_estado	Regla condicional (1 si estado = “Cancelada”, 0 en otro caso)	Indicador binario para KPI de cancelación
fact_reserva.flag_noshow	nombre_estado	Regla condicional (1 si estado = “NoShow”, 0 en otro caso)	Indicador binario para KPI de no-show
fact_reserva.flag_completada	nombre_estado	Regla condicional (1 si estado = “Completada”, 0 en otro caso)	Indicador binario de estadía completada
fact_reserva.flag_ocupada	nombre_estado	Regla condicional (1 si estado = “Completada”, 0 en otro caso)	Se utilizó como proxy de ocupación operativa real

Campo destino	Campo origen	Regla aplicada	Comentarios
fact_reserva.sk_fact_reserva (opcional/documental)	Secuencia técnica interna	Generación de identificador técnico secuencial	Puede documentarse aunque no se haya materializado si se omitió por limitaciones del nodo disponible

5. Respuesta a las preguntas de negocio mediante la solución analítica implementada.

A continuación, se presentan los resultados obtenidos a partir del análisis de los datos procesados mediante el modelo dimensional y el proceso ETL.




Figura 1. Ingreso total por canal de reserva

En la Figura 1 se presenta el ingreso total por canal de reserva. Como se observa, existen diferencias significativas entre los canales, lo que indica que algunos concentran una mayor proporción de los ingresos. Esto sugiere la importancia de identificar y potenciar los canales más rentables.




Figura 2. Ingreso total por propiedad

En la Figura 2 se presenta el ingreso total por propiedad. Se evidencia que ciertas propiedades generan mayores ingresos que otras, lo que puede estar asociado a factores como ubicación, demanda o capacidad operativa.




Figura 3. Tasa de cancelación por canal

En la Figura 3 se muestra la tasa de cancelación por canal de reserva. Se observa que algunos canales presentan mayores niveles de cancelación, lo que representa un riesgo operativo y puede impactar negativamente en la planificación y ocupación.




Figura 4. Tasa de no-show por canal

En la Figura 4 se presenta la tasa de no-show por canal. Este indicador permite identificar la frecuencia con la que los clientes no se presentan, lo cual afecta directamente la eficiencia operativa y el aprovechamiento de la capacidad disponible.




Figura 5. Tasa de ocupación por propiedad

En la Figura 5 se muestra la tasa de ocupación por propiedad. Se observa que algunas propiedades presentan un mayor nivel de ocupación, lo cual refleja un mejor uso de los recursos disponibles y mayor demanda.




Figura 6. ADR por propiedad

En la Figura 6 se presenta el ADR (Average Daily Rate) por propiedad. Este indicador refleja el ingreso promedio por habitación ocupada, permitiendo comparar el desempeño en términos de tarifas entre las distintas propiedades.




Figura 7. RevPAR por propiedad

En la Figura 7 se presenta el RevPAR (Revenue per Available Room) por propiedad. Este indicador combina ocupación y tarifa promedio, proporcionando una visión integral del desempeño económico de cada propiedad.




Figura 8. Ingreso por servicios complementarios por canal

En la Figura 8 se muestra el ingreso generado por servicios complementarios según el canal de reserva. Este análisis permite identificar oportunidades adicionales de generación de ingresos más allá de la habitación.



Figura 9. Antelación promedio de reserva por canal

En la Figura 9 se presenta la antelación promedio de reserva por canal. Este indicador permite analizar el comportamiento de los clientes en cuanto a la planificación de sus reservas, lo cual es clave para la gestión operativa.

6. Conclusiones

6.1. Limitaciones encontradas

Durante el desarrollo del proyecto se identificaron diversas limitaciones que condicionaron el alcance y la precisión de la solución implementada.

En primer lugar, la fuente de datos utilizada corresponde a una base de datos sintética diseñada para simular la operación hotelera, por lo que no refleja la complejidad ni la variabilidad propia de datos reales. Esto implica que ciertos patrones analíticos obtenidos podrían no ser representativos de un entorno productivo real.

En segundo lugar, el dataset transaccional presentó problemas de calidad de datos, incluyendo valores nulos textuales como "NULL" y "NULE" en columnas monetarias, e inconsistencias en los tipos de datos de las columnas de fecha. Si bien estas situaciones fueron corregidas mediante reglas de limpieza en el ETL, su presencia evidencia que una fuente de datos real requeriría un proceso de gobernanza y validación más robusto.

En tercer lugar, el modelo dimensional adoptado centraliza toda la información en una única tabla de hechos (`fact_reserva`), con granularidad a nivel de reserva. Esta decisión simplifica el modelo, pero limita la capacidad de analizar comportamientos a nivel de servicio complementario individual, ya que el ingreso por servicios quedó consolidado como una medida agregada.

Finalmente, la capa analítica implementada en Python sobre Google Colab opera de forma estática sobre archivos CSV exportados por KNIME, lo que implica que cualquier actualización de los datos fuente requiere volver a ejecutar manualmente el flujo ETL completo, sin automatización ni programación de cargas incrementales.

6.2. Posibles mejoras futuras

Con base en la experiencia adquirida durante el proyecto, se identifican las siguientes oportunidades de mejora para una versión más avanzada de la solución.

Se recomienda incorporar una segunda tabla de hechos orientada al consumo de servicios complementarios, con granularidad a nivel de transacción por servicio, lo que permitiría análisis más detallados sobre el comportamiento de consumo de los huéspedes y el aporte real de cada servicio a los ingresos de la propiedad.

Sería valioso implementar dimensiones de cambio lento (Slowly Changing Dimensions, SCD) para entidades como huésped y propiedad, de manera que el modelo pueda registrar y analizar cambios históricos en atributos como el segmento de cliente, la categoría de la propiedad o el canal de reserva preferido.

Adicionalmente, la solución se beneficiaría de la automatización del proceso ETL mediante la programación de ejecuciones periódicas y la incorporación de cargas incrementales, en lugar de cargas completas, para mejorar la eficiencia operativa en entornos con volúmenes de datos crecientes.

Por último, la capa analítica podría evolucionar hacia una solución de visualización interactiva mediante herramientas como Power BI, Tableau o Looker Studio, lo que facilitaría el consumo de los KPIs por parte de los usuarios de negocio sin necesidad de conocimientos de programación.

6.3. Conclusiones

El presente proyecto permitió diseñar e implementar una solución funcional de Inteligencia de Negocios para una cadena hotelera simulada, abarcando todas las capas del proceso: desde el modelado de la base de datos transaccional en PostgreSQL, pasando por el diseño del modelo dimensional tipo estrella, la implementación del proceso ETL en KNIME Analytics Platform y la construcción de una capa analítica en Python.

El proceso ETL demostró ser la etapa más compleja del proyecto, dado que requirió enfrentar problemas reales de calidad de datos, consolidar registros repetidos derivados de la naturaleza de la fuente, y derivar métricas analíticas clave como noches de estadia, antelación de reserva e ingresos desagregados por componente. La documentación detallada de cada regla aplicada garantiza la trazabilidad y reproducibilidad del proceso.

El modelo dimensional resultante ofrece una base sólida para responder las preguntas de negocio definidas, permitiendo analizar la ocupación, los ingresos y el comportamiento de los huéspedes desde múltiples dimensiones. Los KPIs implementados —Tasa de Ocupación, ADR, RevPAR, Tasa de Cancelación y Tasa de No-Show— cubren

las necesidades analíticas de los distintos usuarios de información identificados, desde la Gerencia General hasta el área de Revenue Management.

En términos generales, el proyecto evidenció que una solución de BI bien estructurada transforma datos operacionales dispersos en conocimiento accionable, y que la calidad del modelo dimensional y del proceso ETL es determinante para la confiabilidad de los análisis resultantes.

Referencias Bibliográficas

Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley.

Inmon, W. H. (2005). *Building the Data Warehouse* (4th ed.). Wiley.

KNIME AG. (2024). *KNIME Analytics Platform Documentation*. Recuperado de <https://docs.knime.com>

PostgreSQL Global Development Group. (2024). *PostgreSQL 16 Documentation*. Recuperado de <https://www.postgresql.org/docs/>

McKinney, W. (2022). *Python for Data Analysis* (3rd ed.). O'Reilly Media.

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>

Waskom, M. (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>